Evidencia — LAB-01 — Anonimización y reto

Dato	Valor
Estudiante	Cristopher Enrique Sánchez Castañeda
Matrícula	20434863
Grupo	403
Actividad	Actividades 5 y 6 — Anonimización y análisis de reidentificación
Script	`sql/04-anonimizacion.sql`
Fecha de ejecución	23/10/2026, 18:55 h

Paso 1. Generalización de la edad (12.1)

```
PS C:\Users\crist\Documents\LAB-01> docker exec -it lab01-postgres psql -U postgres -d lab01 -P p
r=off -e -f /sql/04-anonimizacion.sql
SELECT
  CASE WHEN edad BETWEEN 18 AND 30 THEN '18-30'
       WHEN edad BETWEEN 31 AND 45 THEN '31-45'
       ELSE '46+' END AS rango_edad,
  COUNT(*) AS total
FROM clientes
GROUP BY 1;
 rango_edad | total
------------+-------
 31-45      |     4
 46+        |     1
(2 rows)
```

Paso 2. Generalización de la región (12.2)

```
PS C:\Users\crist\Documents\LAB-01> docker exec -it lab01-postgres psql -U postgres -d lab01 -P
r=off -e -f /sql/04-anonimizacion.sql
(2 rows)

SELECT LEFT(codigo_postal, 2) AS region, COUNT(*) AS total
FROM clientes
GROUP BY 1;
 region | total
--------+-------
 82     |     1
 80     |     3
 81     |     1
(3 rows)
```

Paso 3. Combinación de atributos (12.3)

```
PS C:\Users\crist\Documents\LAB-01> docker exec -it lab01-postgres psql -U postgres -d lab01 -P
r=off -e -f /sql/04-anonimizacion.sql
SELECT
  CASE WHEN edad BETWEEN 18 AND 30 THEN '18-30'
       WHEN edad BETWEEN 31 AND 45 THEN '31-45'
       ELSE '46+' END AS rango_edad,
  LEFT(codigo_postal, 2) AS region,
  COUNT(*) AS total
FROM clientes
GROUP BY 1, 2;
 rango_edad | region | total
------------+--------+-------
 31-45      | 81     |     1
 46+        | 82     |     1
 31-45      | 80     |     3
(3 rows)
```

Paso 4. Supresión de grupos pequeños con `HAVING COUNT(*) >= 5` (12.4)

```
PS C:\Users\crist\Documents\LAB-01> docker exec -it lab01-postgres psql -U postgres -d lab01 -P pa
r=off -e -f /sql/04-anonimizacion.sql
SELECT
  CASE WHEN edad BETWEEN 18 AND 30 THEN '18-30'
       WHEN edad BETWEEN 31 AND 45 THEN '31-45'
       ELSE '46+' END AS rango_edad,
  LEFT(codigo_postal, 2) AS region,
  COUNT(*) AS total
FROM clientes
GROUP BY 1, 2
HAVING COUNT(*) >= 5;
 rango_edad | region | total
------------+--------+-------
(0 rows)
```

Paso 5. Reto: consulta modificada

```
PS C:\Users\crist\Documents\LAB-01> docker exec -it lab01-postgres psql -U postgres -d lab01 -P page
r=off -e -f /sql/04-anonimizacion.sql

SELECT MIN(total) AS k_original
FROM (
  SELECT COUNT(*) AS total
  FROM clientes
  GROUP BY
    CASE WHEN edad BETWEEN 18 AND 30 THEN '18-30'
         WHEN edad BETWEEN 31 AND 45 THEN '31-45'
         ELSE '46+' END,
    LEFT(codigo_postal, 2)
) t;
 k_original
------------
          1
(1 row)

SELECT
  CASE WHEN edad BETWEEN 18 AND 50 THEN '18-50' ELSE '51+' END AS rango_edad,
  LEFT(codigo_postal, 1) || 'xxxx' AS region,
  COUNT(*) AS total
FROM clientes
GROUP BY 1, 2
HAVING COUNT(*) >= 5;
 rango_edad | region | total
------------+--------+-------
 18-50      | 8xxxx  |     5
(1 row)

SELECT MIN(total) AS k_reto
FROM (
  SELECT COUNT(*) AS total
  FROM clientes
  GROUP BY
    CASE WHEN edad BETWEEN 18 AND 50 THEN '18-50' ELSE '51+' END,
    LEFT(codigo_postal, 1)
) t;
 k_reto
--------
      5
(1 row)
```

Reto	Respuesta
Cambio realizado	**rangos de edad más amplios y región de 2 dígitos a 1 dígito.**
Motivo	los grupos de 1 o 2 personas eran fáciles de reconocer
Resultado obtenido	k subió de 1 a 5, y la consulta ya cumple el umbral de 5.
Riesgo que se pretende reducir	que alguien sea reconocido por su combinación de edad y zona.

Mecanismo utilizado Anonimización por agregación: se eliminan los identificadores, se generalizan los cuasi-identificadores (edad en rangos, código postal en región) y se suprimen los grupos con menos de 5 registros (HAVING COUNT(*) >= 5, umbral didáctico de k-anonimato). Se midió el tamaño de cada grupo para ver qué combinaciones aíslan a una persona. En el reto se generalizó más (rangos de 20 años y región estatal). La salida para dirección se entrega en una vista exclusiva con su propio rol

1. Identificadores directos eliminados: nombre, correo, teléfono, RFC (y el id técnico).
2. Cuasi-identificadores que permanecen: el rango de edad y la región (prefijo del CP). Ciudad y fecha de alta no se publican.
3. Combinaciones que reducen el anonimato: rango de edad más región de 2 dígitos. El prefijo 81 (Los Mochis) y 82 (Mazatlán) tienen un solo cliente, así que esa combinación es una persona. Si además se publicara el conteo por ciudad o por fecha de alta, se podrían cruzar tablas y despejar valores (ataque por diferencia).
4. ¿Qué sucede con grupos pequeños? Un grupo con 1 registro equivale a publicar el dato de una persona: quien sepa que María vive en Mazatlán aprende que es cliente y que tiene 46 años o más. Con 2-3 registros el atacante reduce mucho las opciones y puede usar conocimiento externo para terminar de identificar.
5. ¿Qué atributos deberían generalizarse? Edad (rangos más amplios) y CP (a región estatal o municipal). Si se usara la ciudad, agrupar ciudades pequeñas en "Otras".
6. ¿Qué información debería suprimirse? Todos los grupos con menos de k registros (aquí todos los de 12.3), además de ciudad exacta, fecha_alta exacta y cualquier columna individual.

7. ¿Es correcto decir "100 % anónimo"? No.
   a) La anonimización depende del contexto y de las fuentes externas que existan; ninguna técnica aislada lo garantiza.
   b) Cumplir k >= 5 protege contra identificar a quién pertenece una fila, pero no contra inferir atributos: en el reto el único grupo publicado es 18-50 / 8xxxx / 5, lo que revela que los 5 clientes tienen entre 18 y 50 años y viven en la región 8xxxx (Sinaloa); si sé que alguien es cliente, ya sé su rango de edad (homogeneidad, la limitación que motiva l-diversidad).
   c) Con solo 5 registros, un grupo de k = 5 es la base completa.
   d) Publicaciones repetidas en el tiempo permiten restar resultados y aislar registros nuevos. Lo correcto es hablar de riesgo de reidentificación reducido, no eliminado.